




Pandas: Análise de Dados com Python

A biblioteca essencial para manipulação e análise de dados tabulares com Python.





O que é Pandas?



Dados Tabulares

Manipula dados em **linhas e colunas**, como planilhas Excel



Biblioteca Python

Ferramenta poderosa para **análise de dados** estruturados



Limpeza e Exploração

Essencial para **transformar, limpar e explorar** conjuntos de dados



Series: Dados em Uma Dimensão

O que é uma Series?


Uma **Series** é um array unidimensional com rótulos — cada valor possui um **índice** para identificação rápida.

Exemplo de uso:

```
import pandas as pd

vendas = pd.Series(
    [150, 200, 175],
    index=['Jan', 'Fev', 'Mar']
)
print(vendas)
```

Útil para listas de vendas, temperaturas ou qualquer sequência de valores nomeados.



DataFrame: Dados em Duas Dimensões

Um **DataFrame** é a estrutura central do pandas — uma tabela completa com linhas e colunas, combinando múltiplas Series lado a lado.

```
import pandas as pd

dados = {
    'Nome': ['Ana', 'Bruno', 'Carla'],
    'Idade': [28, 34, 22],
    'Salário': [3500, 5200, 2900]
}

df = pd.DataFrame(dados)
print(df)
```



Como Excel

Estrutura familiar de
tabela com linhas e
colunas

Múltiplas Series

Combina várias
dimensões de dados em
uma só estrutura



Dados Complexos

Ideal para variáveis múltiplas e análises avançadas



Operações Básicas: Seleção e Filtragem

1 Acessar uma coluna

```
df['nome_coluna']
```

2 Filtrar linhas por condição

```
df[df['idade'] > 25]
```

3 Visualizar primeiros registros

```
df.head()
```

 Com apenas uma linha de código, você consegue selecionar, filtrar e inspecionar qualquer conjunto de dados.



Próximos Passos: Explorando Pandas Além do Básico

Agora que você domina os fundamentos, vamos aprofundar nas funcionalidades que tornam o Pandas uma ferramenta indispensável para análise de dados.



Carregar Dados

Importar informações de diversas fontes, como CSVs e bancos de dados.



Limpeza de Dados

Tratar valores ausentes, remover duplicatas e padronizar formatos.



Agregação e Análise

Utilizar funções como `groupby()` para sumarizar e extrair insights.



Combinar DataFrames

Unir diferentes DataFrames usando `merge()`, `join()` ou `concat()`.



Transformações: Criar e Modificar Dados

Criar nova coluna

```
df['salário_dobro'] =  
df['salário'] * 2
```

Operações matemáticas

```
df['salário'].mean()  
df['salário'].sum()  
df['salário'].count()
```

Agrupar dados

```
df.groupby('departamento').sum()
```

+ Nova Coluna


Crie variáveis derivadas diretamente no DataFrame com operações simples

🔺 Matemática Automática

Soma, média e contagem aplicadas a colunas inteiras com um método

📁 Agrupamentos

Consolide dados por categoria com **groupby** para análises segmentadas



Limpeza de Dados: Tratando Valores Ausentes e Duplicados

Dados "sujos" são um desafio comum. O Pandas simplifica a identificação e o tratamento de valores ausentes e registros duplicados, garantindo a qualidade e confiabilidade das suas análises.

Valores Ausentes (NaN)

Valores ausentes (Not a Number - NaN) podem distorcer sua análise. O Pandas oferece ferramentas para detectá-los e decidir como lidar com eles: removendo linhas/colunas ou preenchendo-os.

```
# Contar valores ausentes por coluna
df.isnull().sum()

# Remover linhas com qualquer valor ausente
df.dropna(inplace=True)

# Preencher valores ausentes com a média da coluna
df['coluna'].fillna(df['coluna'].mean(), inplace=True)
```

Registros Duplicados

Registros idênticos ou parcialmente idênticos podem levar a análises enviesadas. É fundamental identificá-los e removê-los para manter a integridade do seu conjunto de dados.

```
# Contar registros duplicados
df.duplicated().sum()

# Remover linhas duplicadas, mantendo a primeira ocorrência
df.drop_duplicates(inplace=True)

# Remover duplicados com base em colunas específicas
df.drop_duplicates(subset=['Nome', 'Email'],
inplace=True)
```

